

第一步建立事故是否发生与速度和流量之间的模型，由于事故是否发生为二值变量，因此采用逻辑回归模型，得到下图所示结果

```
> summary(total_1)

Call:
glm(formula = case ~ spd_dif_1min + spd_dif_2min + spd_dif_3min +
    spd_dif_4min + vol_dif_1min + vol_dif_2min + vol_dif_3min +
    vol_dif_4min, family = binomial(), data = data_1)

Deviance Residuals:
    Min       1Q   Median       3Q      Max
-1.8377  -0.6221  -0.5046  -0.4109   2.2092

Coefficients:
              Estimate Std. Error z value Pr(>|z|)
(Intercept)  -2.843625   0.218590  -13.009  < 2e-16 ***
spd_dif_1min   0.144066   0.026752   5.385 7.23e-08 ***
spd_dif_2min   0.034617   0.038560   0.898  0.36932
spd_dif_3min   0.032496   0.037084   0.876  0.38088
spd_dif_4min   0.091856   0.035668   2.575  0.01002 *
vol_dif_1min   0.029859   0.010082   2.961  0.00306 **
vol_dif_2min   0.024123   0.011816   2.042  0.04119 *
vol_dif_3min   0.009000   0.010198   0.883  0.37750
vol_dif_4min   0.010865   0.009119   1.191  0.23350
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for binomial family taken to be 1)

    Null deviance: 795.64  on 794  degrees of freedom
Residual deviance: 710.26  on 786  degrees of freedom
AIC: 728.26

Number of Fisher Scoring iterations: 4
```

由上可以看出，回归系数比较显著 ( $p < 0.05$ ) 的是事故发生前 1 分钟内，4 分钟内的速度变化值和事故发生前 1 分钟内，2 分钟内的流量变化值。

因此去除不明显的，用显著变量建立新的逻辑回归模型如下

```
> summary(total_2)

Call:
glm(formula = case ~ spd_dif_lmin + spd_dif_4min + vol_dif_lmin +
    vol_dif_2min, family = binomial(), data = data_1)

Deviance Residuals:
    Min       1Q   Median       3Q      Max
-1.9775  -0.6052  -0.5161  -0.4271   2.1572

Coefficients:
              Estimate Std. Error z value Pr(>|z|)
(Intercept)  -2.609642    0.184279  -14.161  < 2e-16 ***
spd_dif_lmin   0.154330    0.025884   5.962 2.49e-09 ***
spd_dif_4min   0.108424    0.032852   3.300 0.000966 ***
vol_dif_lmin   0.030572    0.009964   3.068 0.002153 **
vol_dif_2min   0.028624    0.010878   2.631 0.008506 **
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for binomial family taken to be 1)

    Null deviance: 795.64  on 794  degrees of freedom
Residual deviance: 715.00  on 790  degrees of freedom
AIC: 725

Number of Fisher Scoring iterations: 4
```

从上面的结果可以看出，4 个参数的回归系数都非常显著，我们再用 anova()函数对两个模型进行比较，用卡方检验，可得

```
> anova(total_1,total_2,test="Chisq")
Analysis of Deviance Table

Model 1: case ~ spd_dif_lmin + spd_dif_2min + spd_dif_3min + spd_dif_4min +
    vol_dif_lmin + vol_dif_2min + vol_dif_3min + vol_dif_4min
Model 2: case ~ spd_dif_lmin + spd_dif_4min + vol_dif_lmin + vol_dif_2min
  Resid. Df Resid. Dev Df Deviance Pr(>Chi)
1       786      710.26
2       790      715.00 -4   -4.7374   0.3153
```

可以看出  $p=0.3153$ ,并不显著，因此用后面的四个变量模型和前面的拟合的一样好。所以就可以得到最佳模型如下

$\text{logit}(p) = -2.6096 + 0.1543\text{spd\_dif\_1min} + 0.1084\text{spd\_dif\_4min} + 0.0306\text{vol\_dif\_1min}$   
 $+ 0.0286\text{vol\_dif\_2min}; y \sim \text{dbern}(p).$